IA para identificação de padrões discursivos de culpabilização da vítima em notícias

Bruna De Marco[1], **Maria Clara G. Soares**[2]

[1]Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

blnmarco@sga.pucminas.com.br, maria.galvao@sga.pucminas.br

1. Introdução

A violência contra a mulher apresenta um crescimento constante no cenário contemporâneo, consolidando-se como um dos maiores desafios estruturais da sociedade. Atualmente, as mídias digitais e redes sociais figuram como os principais vetores de disseminação de informações, exercendo um papel determinante tanto na exposição de fatos quanto na formação da opinião pública. Essa capacidade de influência permite que a narrativa midiática interfira diretamente na percepção social de crimes de gênero, muitas vezes representando as mulheres não como vítimas, mas como possíveis culpadas. Tal estigmatização ocorre de forma explícita ou implícita, dependendo do contexto linguístico e das escolhas editoriais adotadas na veiculação da notícia.

Diante desse cenário, a vasta produção diária de conteúdos e a velocidade dos acontecimentos recentes tornam a verificação manual de padrões de culpabilização de vítimas em noticiários uma tarefa inviável para seres humanos. Nesse contexto, a evolução da Inteligência Artificial (IA) e, especificamente, do Processamento de Linguagem Natural (PLN), oferece ferramentas que podem contribuir nesse reconhecimento de forma automatizada. O uso dessas tecnologias não apenas contribui para o avanço do Aprendizado de Máquina, mas também podem permitir a identificação de vieses e o desenvolvimento de uma ética algorítmica mais precisa. Ao detectar preconceitos enraizados na sociedade, os sistemas podem evidenciar como a subjetividade humana e o viés algorítmico influenciam a percepção pública sobre os casos de violência feminina, e fornecer evidências para uma cobertura midiática mais completa.

Este tema se justifica pela necessidade de compreender como discursos de culpabilização da vítima continuam circulando no espaço público e midiático, contribuindo para a naturalização da violência e para a manutenção de barreiras simbólicas enfrentadas por mulheres ao buscar denúncia e justiça. Em fevereiro de 2026, a Agência Brasil destacou um caso em que o agressor construiu uma narrativa para responsabilizar a mulher pelo crime cometido [Agência Brasil 2026], evidenciando como processos discursivos podem reforçar a revitimização e o machismo. Nesse contexto, o uso da inteligência artificial mostra-se relevante por possibilitar a análise sistemática de grandes volumes de notícias e por oferecer suporte à identificação de padrões que, muitas vezes, poderiam passar despercebidos em análises exclusivamente manuais.

Embora existam muitos trabalhos que utilizem a Inteligência Artificial para o reconhecimento e a identificação de vieses midiáticos de forma geral, como hiperpartidarismo e trechos enviesados [Cruz et al. 2020, Chen et al. 2020], a aplicação dessas técnicas para a identificação da responsabilização de mulheres vítimas de violência de gênero perma-

nece pouco explorada, principalmente no idioma português. Na maioria das pesquisas em português, o foco recai sobre a identificação explícita de sexismo [Braga et al. 2020].

A escassez de estudos nesse ramo específico justifica-se por dois fatores principais. O primeiro diz respeito à complexidade linguística do português e à falta de bases de dados específicas para vieses de gênero, o que frequentemente obriga os pesquisadores a construírem seus próprios recursos do zero. Além disso, diferentemente de discursos de ódio, a culpabilização em textos jornalísticos se manifesta de forma velada, em vez de direta, construída por meio da escolha de palavras e de pontos de vista narrativos [**?**]

Diversos estudos têm explorado o uso da IA como detectores de padrões discursivos, principalmente na questão de identificação de vieses e discursos de ódio, e a IA tem tido ótimas performances no reconhecimento desses padrões. Ao mesmo tempo, outros estudos também mostram como a IA pode ser facilmente influenciada pelas diversas fontes da internet e pelo próprio usuário, passando a utilizar informações enviesadas e repassá-las, por não ter um julgamento correto sobre estas. As pesquisas selecionadas apresentam diferentes métodos de detecção em diferentes contextos, com análise de comentários, atenção hierárquica e até a geração de narrativas, o que é interessante para a base deste trabalho.

No âmbito da identificação de conteúdos ofensivos em português, Braga et al. propuseram a criação e caracterização de uma base de dados sexista, a partir de comentários coletados em sites de notícias. A estratégia adotada consistiu na rotulação manual dos comentários reais relacionados a feminicídio e assédio, por diferentes usuários, seguidamente do treinamento de modelos de aprendizado de máquina, para a classificação automatizada de discursos sexistas e não sexistas. A principal vantagem deste estudo é o foco no idioma português, comprovando que o Processamento de Linguagem Natural (PLN) é capaz de reconhecer e mapear padrões de machismo no idioma com alta precisão. Contudo, o estudo foca em classificar textos com agressões explícitas, o que difere da forma como textos jornalísticos são escritos, de forma implícita. Este trabalho se associa ao problema motivador ao demonstrar que o viés de gênero possui padrões detectáveis, e pode servir de base metodológica para o rastreamento da culpabilização da vítima em notícias.

Buscando superar a limitação de análise em palavras-chave e lidar com textos complexos e longos, Cruz et al. utilizaram das Redes de Atenção Hierárquica para detectar notícias enviesadas, com um mecanismo de avaliação de importância de palavras em frases presentes no contexto global de notícias. A principal vantagem dessa abordagem é a interpretabilidade por meio das Redes de Atenção Hierárquica, pois o modelo permite identificar quais sentenças e termos foram decisivas para a classificação do viés. No entanto, o estudo possui uma limitação com o foco no reconhecimento de viés político e partidário em notícias escritas no idioma inglês. Entretanto, a associação com esta pesquisa ocorre pela viabilidade de adaptar esse mecanismo para localizar os vieses de gênero em expressões específicas que a sustentam e permitir o reconhecimento da culpabilização da mulher em notícias nacionais.

Em outra perspectiva sobre a língua portuguesa, Silva et al. analisaram a presença de vieses de gênero em textos gerados por modelos de linguagem, e como podem reforçar estereótipos de gênero ao gerar as narrativas. A estratégia adotada consistiu em solicitar à inteligência artificial o complemento de trechos literários de livros clássicos em por-

tuguês, nos quais o gênero se encontrava implícito, assim, possibilitando a observação de decisão da máquina. A principal vantagem deste estudo é a comprovação de que o viés de gênero na língua portuguesa é estrutural, e, muitas vezes, se manifesta de forma sutil nas escolhas lexicais. Porém, o artigo avalia a inteligência artificial criando histórias fictícias, enquanto este trabalho foca em detecção de viés em textos reais, escritos por humanos. Entretanto, a associação com esta pesquisa é direta, pois demonstra que as palavras possuem um peso de gênero invisível que influencia a percepção do público, fornecendo base para analisar como essa linguagem contribui para a culpabilização da vítima. go2024. Portanto, métodos tradicionais baseados na busca por palavras-chave tendem a falhar ao tentar capturar o posicionamento implícito de culpabilização da vítima [Pavan and Paraboni 2024].

Desta forma, o principal objetivo desse trabalho é investigar a aplicação de técnicas de Processamento de Linguagem Natural (PLN) para a identificação automatizada de padrões discursivos que promovam a culpabilização da vítima em notícias sobre violência de gênero, analisando as escolhas lexicais e os pontos de vista narrativos utilizados pelas mídias, além de discutir como essa detecção pode contribuir para a ética algorítmica.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico, detalhando os conceitos de violência contra a mulher e a formação do viés discursivo no jornalismo. A Seção 3 aborda os trabalhos relacionados, onde serão discutidos ferramentas e estudos que em que esta pesquisa se baseia. A Seção 4 descreve a metodologia proposta para a coleta e o processamento dos dados. A Seção 5 apresenta os resultados esperados e as discussões sobre o tema. Por fim, a Seção 6 traz as considerações finais e as perspectivas para trabalhos futuros.

2. Referencial Teórico

2.1. Violência contra a mulher e culpabilização da vítima

A violência contra a mulher constitui um problema social estrutural, atravessado por desigualdades históricas de gênero e por práticas simbólicas que afetam a forma como esses casos são compreendidos socialmente. Para além da agressão em si, a forma como a violência é narrada e interpretada no espaço público influencia diretamente a percepção social sobre a vítima, o agressor e o próprio acontecimento. Nesse contexto, destaca-se a culpabilização da vítima, entendida como um processo discursivo em que a responsabilidade pela violência sofrida é, total ou parcialmente, deslocada para a mulher.

Esse deslocamento pode ocorrer de forma explícita, quando a narrativa associa diretamente o ocorrido ao comportamento da vítima, ou de modo implícito, por meio de escolhas lexicais, enquadramentos narrativos e seleções informacionais que sugerem corresponsabilidade. Assim, a culpabilização da vítima não apenas enfraquece o reconhecimento da violência como violação de direitos, mas também contribui para a naturalização da violência de gênero. Tal processo é especialmente relevante em ambientes midiáticos, nos quais a circulação de discursos interfere na construção da opinião pública e nas interpretações sobre os fatos. Desse modo, analisar padrões discursivos de culpabilização da vítima em notícias torna-se relevante para compreender como a linguagem participa da manutenção de desigualdades de gênero e da reprodução simbólica da violência.

2.2. Viés discursivo em notícias e sua identificação por Inteligência Artificial

O viés em textos jornalísticos não se restringe a opiniões explícitas, podendo também aparecer de forma sutil, por meio de enquadramentos narrativos, omissões e associações implícitas que orientam a leitura do público. O viés midiático pode se manifestar em diferentes níveis do texto [Rodrigo-Ginés et al. 2024], o que permite compreender a culpabilização da vítima como um padrão discursivo que reforça desigualdades e preconceitos de gênero.

A identificação desses padrões torna-se especialmente desafiadora diante do grande volume de conteúdos produzidos e compartilhados em ambientes digitais. Nesse contexto, a Inteligência Artificial, especialmente por meio do Processamento de Linguagem Natural, oferece recursos relevantes para a análise de textos, permitindo reconhecer regularidades linguísticas, relações semânticas e indícios de viés em larga escala. Essas técnicas tornam possível examinar não apenas palavras isoladas, mas também contextos, recorrências e estruturas discursivas que contribuem para a construção de determinados sentidos no texto jornalístico.

No caso desta pesquisa, o uso da IA mostra-se pertinente porque a culpabilização da vítima nem sempre se apresenta de forma direta, podendo surgir em formulações sutis e em escolhas narrativas específicas. Dessa forma, o PLN pode contribuir para a identificação automatizada desses padrões em grandes volumes de notícias, ampliando as possibilidades de análise. Ao mesmo tempo, é necessário considerar que sistemas de IA não são neutros e podem reproduzir vieses presentes nos dados de treinamento, o que exige cuidado metodológico e reflexão crítica em sua aplicação.

3. Trabalhos relacionados

Diversos estudos têm explorado o uso da IA como detectores de padrões discursivos, principalmente na questão de identificação de vieses e discursos de ódio, e a IA tem tido ótimas performances no reconhecimento desses padrões. Ao mesmo tempo, outros estudos também mostram como a IA pode ser facilmente influenciada pelas diversas fontes da internet e pelo próprio usuário, passando a utilizar informações enviesadas e repassá-las, por não ter um julgamento correto sobre estas. As pesquisas selecionadas apresentam diferentes métodos de detecção em diferentes contextos, com análise de comentários, atenção hierárquica e até a geração de narrativas, o que é interessante para a base deste trabalho [Braga et al. 2020, Cruz et al. 2020, Silva et al. 2025, Chen et al. 2020, Rodrigo-Ginés et al. 2024, Pavan and Paraboni 2024].

No âmbito da identificação de conteúdos ofensivos em português, Braga et al. [Braga et al. 2020] propuseram a criação e caracterização de uma base de dados sexista, a partir de comentários coletados em sites de notícias. A estratégia adotada consistiu na rotulação manual dos comentários reais relacionados a feminicídio e assédio, por diferentes usuários, seguidamente do treinamento de modelos de aprendizado de máquina, para a classificação automatizada de discursos sexistas e não sexistas. A principal vantagem deste estudo é o foco no idioma português, comprovando que o Processamento de Linguagem Natural (PLN) é capaz de reconhecer e mapear padrões de machismo no idioma com alta precisão. Contudo, o estudo foca em classificar textos com agressões explícitas, o que difere da forma como textos jornalísticos são escritos, de forma implícita. Este trabalho se associa ao problema motivador ao demonstrar que o viés de gênero possui padrões

detectáveis, e pode servir de base metodológica para o rastreamento da culpabilização da vítima em notícias.

Buscando superar a limitação de análise em palavras-chave e lidar com textos complexos e longos, Cruz et al. [Cruz et al. 2020] utilizaram das Redes de Atenção Hierárquica para detectar notícias enviesadas, com um mecanismo de avaliação de importância de palavras em frases presentes no contexto global de notícias. A principal vantagem dessa abordagem é a interpretabilidade por meio das Redes de Atenção Hierárquica, pois o modelo permite identificar quais sentenças e termos foram decisivas para a classificação do viés. No entanto, o estudo possui uma limitação com o foco no reconhecimento de viés político e partidário em notícias escritas no idioma inglês. Entretanto, a associação com esta pesquisa ocorre pela viabilidade de adaptar esse mecanismo para localizar os vieses de gênero em expressões específicas que a sustentam e permitir o reconhecimento da culpabilização da mulher em notícias nacionais.

Em outra perspectiva sobre a língua portuguesa, Silva et al. [Silva et al. 2025] analisaram a presença de vieses de gênero em textos gerados por modelos de linguagem, e como podem reforçar estereótipos de gênero ao gerar as narrativas. A estratégia adotada consistiu em solicitar à inteligência artificial o complemento de trechos literários de livros clássicos em português, nos quais o gênero se encontrava implícito, assim, possibilitando a observação de decisão da máquina. A principal vantagem deste estudo é a comprovação de que o viés de gênero na língua portuguesa é estrutural, e, muitas vezes, se manifesta de forma sutil nas escolhas lexicais. Porém, o artigo avalia a inteligência artificial criando histórias fictícias, enquanto este trabalho foca em detecção de viés em textos reais, escritos por humanos. Entretanto, a associação com esta pesquisa é direta, pois demonstra que as palavras possuem um peso de gênero invisível que influencia a percepção do público, fornecendo base para analisar como essa linguagem contribui para a culpabilização da vítima.

Além desses estudos, Chen et al. [Chen et al. 2020] propuseram uma abordagem para detectar viés em notícias a partir da distribuição de trechos enviesados ao longo do texto, considerando frequência, posição e ordem desses elementos. A principal contribuição desse trabalho é demonstrar que o viés pode ser analisado em nível de artigo, e não apenas por palavras isoladas. Embora o estudo trate do viés midiático de forma ampla, sem foco específico na culpabilização da vítima, ele contribui para esta pesquisa ao mostrar que a organização estrutural do texto pode revelar padrões de parcialidade em notícias.

Rodrigo-Ginés et al. [Rodrigo-Ginés et al. 2024] realizaram uma revisão sistemática sobre detecção de viés midiático, discutindo suas formas de manifestação e os principais métodos automáticos utilizados para identificá-lo. A vantagem do estudo está na construção de uma base teórica ampla, que ajuda a compreender o viés como um fenômeno presente em escolhas lexicais, enquadramentos narrativos e omissões. Apesar de não propor um modelo específico para culpabilização da vítima, o trabalho contribui para fundamentar conceitualmente a análise de padrões discursivos enviesados em textos jornalísticos.

Por fim, Pavan e Paraboni [Pavan and Paraboni 2024] apresentaram um benchmark para detecção de posicionamento em português no cenário zero-shot, voltado à

identificação de atitudes favoráveis, contrárias ou neutras em textos. Embora o estudo não trate diretamente de culpabilização da vítima, sua contribuição é relevante por abordar a identificação de posicionamentos implícitos em língua portuguesa. Essa perspectiva se relaciona ao presente trabalho porque a responsabilização da vítima pode ocorrer de forma indireta, por meio de escolhas narrativas que sugerem julgamento, dúvida ou corresponsabilidade.

4. Metodologia

Nesta seção, descrevemos nosso processo de coleta e análise de banco de dados de notícias, e o processo de reconhecimento de culpabilização das vítimas por meio de PLN/LLM. Sendo uma pesquisa aplicada e de caráter exploratório, utilizaremos uma estratégia metodológica dividida em três partes: a coleta de reportagens em grandes portais baseada em critérios pré-selecionados, a estruturação dos dados e a classificação discursiva. Para isso, utilizaremos uma abordagem mista, na qual integramos a avaliação qualitativa dos textos e métricas quantitativas de concordância. Será aplicado um modelo classificador via API na plataforma Azure para processar as narrativas e auxiliar na identificação de vieses estruturais. O modelo atuará na identificação contextual, enquanto a tomada de decisão definitiva e a validação do rótulo permanecerão sob nossa responsabilidade, como pesquisadoras.

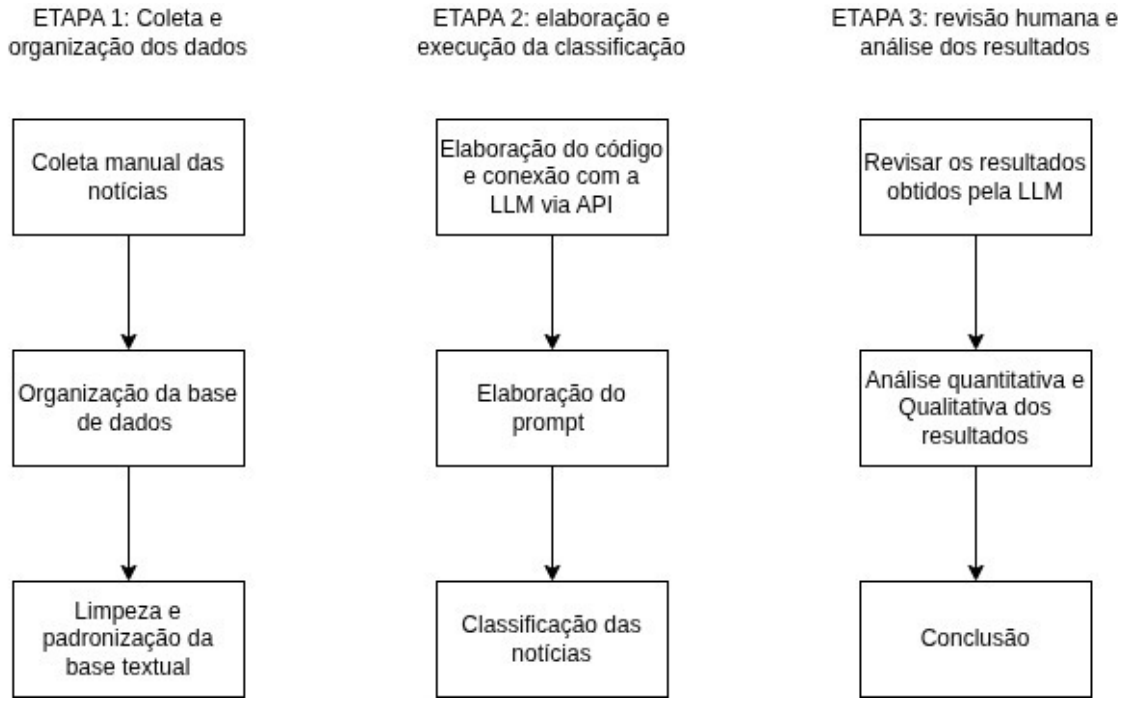


Figura 1. Fluxograma das etapas metodológicas propostas para a coleta, classificação e análise dos dados.

4.1. Coleta de Dados

Para a coleta de dados, inicialmente foi determinada a seleção de 100 notícias no total, sendo 20 para cada um dos cinco portais de grande notoriedade pré-selecionados. Todas as publicações devem ser em língua portuguesa e com foco no Brasil, englobando as

seguintes fontes: Agência Brasil, G1, CNN Brasil, UOL Notícias e Estado de Minas. Em casos em que não seja possível encontrar notícias suficientes de determinada categoria, o portal O Tempo será utilizado como substituto para cobrir possíveis falhas de coleta. Além disso, o período determinado para a busca compreende os anos de 2020 a 2026, com prioridade de escolha para o intervalo de 2023 a 2026, com o intuito de obter um dataset atualizado. Ao fazer a busca, as notícias incluídas na base de dados devem atender os critérios selecionados para serem incluídas na pesquisa:

- Estar em língua portuguesa;
- Ser publicada em portal jornalístico;
- Tratar de temas como violência contra a mulher, feminicídio, violência doméstica, assédio e/ou crime de gênero;
- Possuir título e corpo textual acessíveis;
- Apresentar data de publicação;
- Apresentar fonte identificável;
- Possuir link de acesso;
- Possuir conteúdo verdadeiramente jornalístico, e não apenas opinativo ou publicitário.

As eliminações das coletas feitas serão realizadas em casos em que haja somente: comentários de leitores, postagens de redes sociais, vídeos sem transcrição, notícias sem corpo textual completo, textos duplicados, textos opinativos, editoriais ou colunas, notícias que apenas mencionem o tema tratado de forma genérica, sem tratar o tema de forma direta, páginas de tags, listas automáticas ou páginas de busca, e notícias sem data, fonte ou link identificável. Acresce que a busca será realizada de forma manual por meio do buscador do Google, portanto, para garantir a precisão da coleta, serão utilizados os seguintes operadores avançados de busca:

- Operador site:: para busca em portais específicos
- Aspas (): Busca uma determinada expressão especificada
- Operador OR: Buscar uma palavra ou outra
- Operadores after: e before:: Delimitam um período para a busca
- Operador de exclusão (-): Remove resultados indesejados

Considerando-se todo esse rigor no mecanismo de busca, a definição de palavras-chave foi elaborada de maneira estratégica para evitar que a coleta se concentre apenas em termos que já sugerem culpabilização prévia, como, por exemplo, “ciúmes” ou “traição”. Para garantir a pluralidade do dataset, os termos de busca foram classificados em quatro grupos principais:

- Palavras-chave gerais: termos utilizados para encontrar notícias mais amplas e relacionadas ao tema, como ”violência contra a mulher”e ”feminicídio”;
- Palavras-chave relacionadas ao agressor: termos utilizados para localizar notícias com casos envolvendo familiares ou relações afetivas, como ”ex-companheiro”e ”suspeito”;
- Palavras-chave relacionadas ao viés discursivo: termos para a identificação do contexto da narrativa, mas que exige uma análise mais cuidadosa, como ”ciúmes”e ”separação”;
- Palavras-chave relacionadas ao contexto social: termos que ajudam a encontrar notícias mais analíticas, como, ”Lei Maria da Penha”e ”medida protetiva”.

A partir desta definição, para evitar que a base de dados criada seja composta somente por notícias com termos que já categorizam o texto diretamente à culpabilização, foi feita uma divisão na quantidade de buscas para o equilíbrio da coleta. Das 20 notícias por portal, 12 devem pertencer à categoria geral definida nas palavras-chave, e 8 devem se encaixar dentro das demais categorias, que estejam relacionadas mais diretamente ao fator culpabilizador.

4.2. Estruturação do dataset

Para a estruturação do dataset desta pesquisa, será construída uma planilha composta por 12 colunas, sendo cada uma responsável por armazenar informações essenciais baseadas nos critérios estabelecidos durante a coleta. As colunas que compõem a base de dados estão descritas na tabela abaixo:

Tabela 1. Descrição das colunas da base de dados.

Coluna	Descrição
id	Código da notícia
coletado_por	Nome da pesquisadora responsável pela coleta
portal	Fonte jornalística da notícia
titulo	Título da notícia
subtitulo	Subtítulo ou linha fina, quando houver
corpo_texto	Corpo textual completo da notícia
data_publicacao	Data de publicação
link	URL da notícia
palavra_chave_usada	Palavra-chave ou expressão usada na busca
tema	Feminicídio, violência doméstica, assédio, agressão, etc
texto_completo	Título + subtítulo + corpo textual
observacoes	Informações adicionais, como notícia duplicada, texto incompleto ou dúvida

Cabe ressaltar que a coluna ”texto_completo”consiste na junção das colunas ”titulo”, ”subtitulo”e ”corpo_texto”. Essa junção tem como objetivo preparar o material integral para a etapa futura de classificação via LLM, garantindo que a análise não se limite a fragmentos e englobe todo o contexto da narrativa.

Para a extração dessas informações, o método utilizado contará com o apoio de uma LLM para auxiliar no processo. Ao disponibilizarmos os links, previamente selecionados de forma manual, para a LLM em questão, espera-se a extração de todos os dados textuais e datas diretamente da URL para otimizar a montagem da planilha. Com isto, faremos uma verificação dos dados extraídos manualmente para evitar possíveis erros nesta etapa.

4.3. Classificação Discursiva

Para a etapa de classificação discursiva, utilizaremos técnicas de Processamento de Linguagem Natural (PLN), que estão integradas em uma LLM, acessadas via API na plataforma Azure. A escolha desta ferramenta, se dá pela sua capacidade de reconhecer e analisar textos de forma mais contextual, compreendendo as informações como título,

subtítulo e o corpo do texto, além de compreender como os personagens presentes na narrativa são tratados, e como é distribuída a responsabilidade em cada narrativa.

O processo funcionará por meio do envio do conteúdo do dataset unificado na coluna ”texto_completo”de cada notícia para o modelo, utilizando um prompt fixo e padronizado, no qual conterá uma definição clara do que é a culpabilização da vítima e os critérios de classificação estabelecidos para a pesquisa.

Desta forma, como resultado do processamento, espera-se que a LLM classifique o texto e retorne um rótulo sugerido, indicando se o texto jornalístico é neutro ou se possui algum resquício de culpabilização da vítima em questão. Além deste rótulo, será questionado a inteligência artificial os trechos em que a levaram a determinada decisão, para a justificativa do rótulo escolhido.

Tendo em vista que o tema da pesquisa abordado é algo complexo, a classificação algorítmica feita pela LLM será revisada de forma manual após o processamento com o uso de API, de forma que as análises críticas das justificativas geradas pela LLM nos permitam confirmar, corrigir ou ajustar os rótulos atribuídos para a realização da pesquisa.

4.4. Cronograma

Para garantir a organização da pesquisa, as etapas metodológicas descritas nas subseções anteriores foram estruturadas em um cronograma de execução de duas semanas no mês de junho, iniciando-se no dia 07/06/2026 (sete de junho de dois mil e vinte e seis) e finalizando-se no dia 21/06/2026 (vinte e um de junho de dois mil e vinte e seis), concentrando as atividades de coleta, implementação técnica e validação analítica. Abaixo temos a tabela com mais detalhes das fases e prazos estipulados para a conclusão da pesquisa.

Tabela 2. Cronograma da metodologia

Semana 1 (07/06 a 14/06)	Definir palavras-chaves para a busca, coletar notícias manualmente, criar e tratar a base de dados.
Semana 2 - Parte 1 (14/06 a 17/06)	Criar código python conectando o modelo classificador através de uma API, rodar a classificação na base de dados.
Semana 2 - Parte 2 (17/06 a 21/06)	Analisar os resultados encontrados, realizar a conferência manual, discutir divergências e ética algorítmica (se houver), escrever as partes finais do artigo.

5. Resultados Esperados

Nesta seção, apresentamos os possíveis cenários que poderiam ser encontrados a partir da metodologia proposta, bem como as expectativas quanto ao comportamento do modelo de classificação. Tendo em vista que esta pesquisa possui um caráter exploratório, os resultados discutidos estarão fundamentados nos trabalhos relacionados previamente mapeados, em nossos conhecimentos prévios sobre o tema e na capacidade analítica dos Modelos de Linguagem (LLMs). A expectativa é de que a integração com o modelo via API seja capaz de reconhecer além das palavras-chave isoladas, sendo capaz de interpretar a estrutura e a semântica do texto como um todo, identificando partes sutis da narrativa relacionadas à culpabilização da vítima. Desta forma, para a representação do cenário,

coletamos algumas notícias reais, que serão utilizadas para simular o fluxo de entrada de dados e demonstrar as classificações e justificativas esperadas por parte da inteligência artificial.

Destacamos aqui, dois cenários hipotéticos, utilizando notícias reais:

Cenário 1 - Notícia Neutra:

- **Título:** Mulher é morta a tiros por ex-companheiro na zona Norte de SP
- **Link:** `https://www.cnnbrasil.com.br/nacional/sudeste/sp/mulher-e-morta-a-tiros-por-ex-companheiro-na-zona-norte-de-sp/`
- **Portal:** CNN Brasil

Cenário 2 - Notícia com Culpabilização Implícita:

- **Título:** Advogado mata esposa por não aceitar separação e se entrega à polícia em SC
- **Link:** `https://noticias.uol.com.br/cotidiano/ultimas-noticias/2026/03/20/advogado-mata-esposa-por-nao-aceitar-separacao-e-se-entrega-a-policia-em-sc.ghtm`
- **Portal:** UOL Notícias

Em um primeiro cenário, onde a notícia não possui nenhum viés, é esperado que ao receber os dados propostos para identificação da culpabilização, como o título, o subtítulo e o corpo da notícia, que já foram previamente separados em etapas anteriores, assim como a seleção de notícias, a LLM seja capaz de reconhecer que a notícia apresenta padrões que coincidem com uma notícia neutra, não sendo localizado nenhum termo que aponte o texto como enviesado, sem usos de adjetivos, insinuações ou contextualizações que revertam a responsabilidade da agressão do autor do crime para a vítima, além de ser objetiva, direta e isolando a culpa no autor do crime.

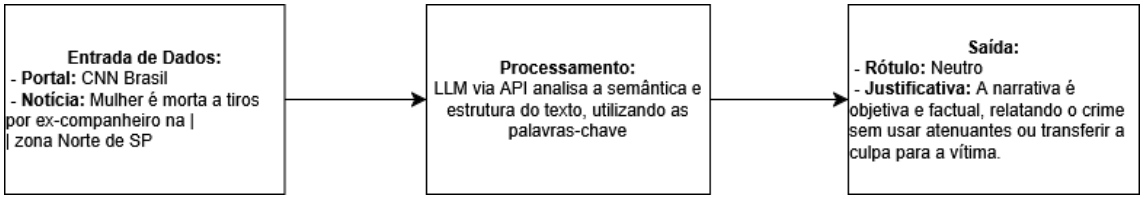


Figura 2. Fluxo de processamento e classificação esperado para o Cenário 1 (Notícia Neutra).

No segundo cenário, verificamos que há indícios de motivação para o crime cometido contra a vítima, que neste caso, seria o pedido de divórcio pela esposa, e a negação do autor do crime com a motivação do "medo de perder a filha". A culpabilização, para este caso é implícita, e o que se espera da LLM é este reconhecimento, por meio da identificação dos termos "por não aceitar a separação" como termo agravante, percebendo assim, além do próprio contexto da notícia, que isto causa um efeito de justificativa aceitável diante do crime cometido, responsabilizando a mulher de forma indireta pelo crime.

Por fim, é importante ressaltar que o uso exclusivo de Modelos de Linguagem (LLMs) apresenta limitações no reconhecimento automatizado, podendo gerar falsos positivos durante a análise. No entanto, mesmo com essas ressalvas, essas ferramentas

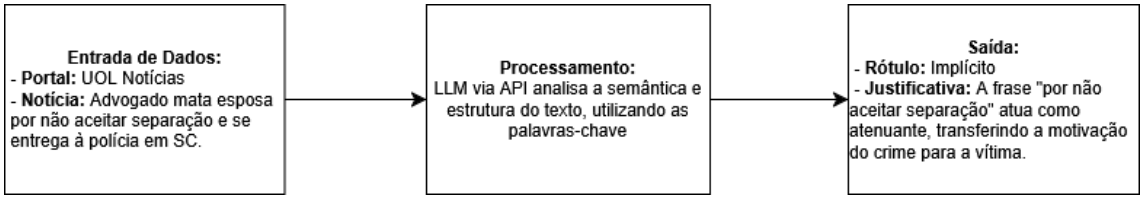


Figura 3. Fluxo de processamento e classificação esperado para o Cenário 2 (Culpabilização Implícita).

atuam como grandes auxiliadoras no processamento de amplos volumes de dados textuais. Por essa questão, e como forma de garantir resultados mais corretos, é importante o reconhecimento humano do trabalho realizado pela IA, para que os erros cometidos possam ser corrigidos com o tempo, e possamos reconhecer as limitações desta tecnologia quanto à contextualização, principalmente em língua portuguesa e em textos implícitos. Desta maneira, o modelo poderia gerar erros de classificação, nos quais, por exemplo, tivéssemos os termos e palavras-chave encontrados sem sua contextualização adequada. Portanto, a avaliação humana é de extrema importância nestas etapas, para garantir a ética e eficácia da pesquisa.

6. Considerações Finais

Este trabalho buscou investigar a aplicação de técnicas de Processamento de Linguagem Natural (PLN) e Modelos de Linguagem (LLMs) na identificação automatizada de padrões discursivos de culpabilização da vítima em notícias sobre violência contra a mulher. A partir da revisão teórica e dos trabalhos relacionados, foi possível observar que, embora existam estudos voltados à detecção de vieses midiáticos, discursos ofensivos, sexismo e posicionamentos implícitos, ainda há uma lacuna significativa em relação à identificação da responsabilização simbólica de mulheres vítimas de violência de gênero em textos jornalísticos em língua portuguesa.

A metodologia proposta procura contribuir para essa área ao estruturar um processo de coleta, organização e análise de notícias publicadas em grandes portais brasileiros. A construção de um dataset específico, associada ao uso de uma LLM via API, permite explorar a capacidade da inteligência artificial de reconhecer não apenas palavras-chave isoladas, mas também escolhas lexicais, enquadramentos narrativos e indícios sutis de deslocamento de responsabilidade para a vítima. Dessa forma, espera-se que o modelo auxilie na identificação inicial de padrões discursivos que poderiam passar despercebidos em uma análise manual de grande escala.

Entretanto, destaca-se que a classificação automatizada não deve ser compreendida como uma decisão definitiva. Por se tratar de um fenômeno complexo, muitas vezes implícito e dependente de contexto, a culpabilização da vítima exige interpretação crítica e validação humana. Assim, a atuação das pesquisadoras permanece essencial para revisar os rótulos sugeridos pela inteligência artificial, analisar possíveis falsos positivos ou falsos negativos e garantir maior rigor ético e metodológico ao processo.

Conclui-se, portanto, que a aplicação de IA nesse campo apresenta potencial relevante tanto para o avanço das pesquisas em PLN quanto para a reflexão sobre ética algorítmica e responsabilidade midiática. Ao evidenciar padrões de linguagem que podem reforçar a revitimização e a naturalização da violência de gênero, este estudo pode

contribuir para uma cobertura jornalística mais cuidadosa, crítica e comprometida com os direitos das mulheres. Como trabalhos futuros, sugere-se a ampliação da base de dados, a comparação entre diferentes modelos de linguagem e o desenvolvimento de métricas específicas para avaliar a presença de culpabilização implícita em notícias.

Referências

Agência Brasil (2026). Caso em itumbiara acende alerta para violência vicária; entenda. Publicado em 14 fev. 2026. Acesso em: 11 mar. 2026.

Braga, M. L. P., Nakamura, F. G., and Nakamura, E. F. (2020). Criação e caracterização de um corpus de discurso sexista em português. In *Anais do Brazilian Workshop on Social Network Analysis and Mining (BRASNAM)*.

Chen, W.-F., Al Khatib, K., Stein, B., and Wachsmuth, H. (2020). Detecting media bias in news articles using gaussian bias distributions. In *Findings of the Association for Computational Linguistics: EMNLP 2020*.

Cruz, A. F., Rocha, G., and Cardoso, H. L. (2020). On document representations for detection of biased news articles. In *Proceedings of the ACM Symposium on Applied Computing*.

Pavan, M. C. and Paraboni, I. (2024). A benchmark for portuguese zero-shot stance detection. *Journal of the Brazilian Computer Society*.

Rodrigo-Ginés, F.-J., Carrillo-de Albornoz, J., and Plaza, L. (2024). A systematic review on media bias detection: What is media bias, how it is expressed, and how to detect it. *Expert Systems with Applications*.

Silva, M. O., Brandão, M. A., and Moro, M. M. (2025). Rewriting stories with llms: Gender bias in generated portuguese-language narratives. *Journal of the Brazilian Computer Society*.